

튜토리얼

월드 모델과 AGI

World Models and AGI


오일석

전북대학교 AI대학 컴퓨터인공지능학부

isoh@jbnu.ac.kr

AGI (Artificial General Intelligence)

■ 영화 속의 AGI



■ AGI의 정의

Artificial general intelligence (AGI)—sometimes called **human-level intelligence AI**—is a type of **artificial intelligence** that would match or surpass human capabilities across virtually all cognitive tasks.^{[1][2]} [\[위키피디아\]](#)

AGI is an AI that can match or exceed the cognitive versatility and proficiency of a well-educated adult.

[Hendrycks2025] Dan Hendrycks et al., "A definition of AGI," arXiv2510.18212v3.

AI 발전의 큰 그림

■ 규칙 기반



- Eliza, Mycin, Cyc, ...

■ 기계 학습



- 필기 숫자 인식, 자동차 번호판 인식, 수표 인식, 의료 진단, ...

■ 딥러닝



- 자연영상 인식 (2012년 AlexNet), 음성 인식, AlphaGo, Atari 게임, ...

■ 트랜스포머 (2017년 "attention is all you need")



- 멀티 모달, 과업 일반화,

■ LLM (2018년 GPT)



- AGI를 향하여...

■ 월드 모델과 피지컬 AI ← 이 튜토리얼의 주제

- AGI를 향하여...



월드 모델이란?

사람의 월드 모델

- 사람은 뇌에 있는 월드 모델을 기반으로,
 - 장면을 **이해** (understanding)하고,
 - 앞으로 벌어질 일을 상상 속에서 **예측** (prediction)하고,
 - 이들 이해와 예측을 통해 계획^{planning}, 추론^{inference}, 리즈닝^{reasoning}의 고차원 지능을 실현함



사람의 월드 모델

■ 사람의 월드 모델에 대한 많은 연구

- 사람 얼굴 영상을 불변 특징 공간에 표현함 [Quiroga2005, Chang2017]
- 특징 공간에서 미래 예측으로 지각함 [Johnson-Laird1983, Rao1999, Nortmann2015]
 - 의사결정 속도가 시신경 전달 속도보다 빠르는데 타자는 어떻게 빠른 공을 칠 수 있나?

■ Judea Pearl의 three layer causal hierarchy [Pearl2009]



Level (Symbol)	Typical Activity	Typical Questions	Examples
1. Association $P(y x)$	Seeing	What is? How would seeing X change my belief in Y ?	What does a symptom tell me about a disease? What does a survey tell us about the election results?
2. Intervention $P(y do(x), z)$	Doing	What if? What if I do X ?	What if I take aspirin, will my headache be cured? What if we ban cigarettes?
3. Counterfactuals $P(y_x x', y')$	Imagining, Retrospection	Why? Was it X that caused Y ? What if I had acted differently?	Was it the aspirin that stopped my headache? Would Kennedy be alive had Oswald not shot him? What if I had not been smoking the past 2 years?



"robot"



"apple"



[Quiroga2005] R. Quiroga et al., "Invariant visual representation by single neurons in the human brain," Nature.

[Chang2017] L. Chang et al., "The code for facial identity in the primate brain," Cell.

[Johnson-Laird1983] Philip Nicholas Johnson-Laird, *Mental Models: Towards a Cognitive Science of Language, Inference, and Consciousness*, Harvard University Press.

[Rao1999] R. Rao et al., "Predictive coding in the visual cortex: a functional interpretation of some extra-classical receptive-field effects," Nature Neuroscience.

[Nortmann2015] Nora Nortmann et al., "Primary visual cortex represents the difference between past and present," Cerebral Cortex.


[Pearl2009] Judea Pearl, *Causality: Models, Reasoning, and Inference*, 2nd Edition, Cambridge University Press.

기계의 월드 모델

■ 모델이란?

- 예) 우주에 대한 모델: Jacob Andreas의 견해 [Andreas2024]

Model 1: The map



Model 2: The orrery



Model 3: The simulator



All models are wrong,
but some are useful.
– George Box

■ 현재 AI는 사람의 월드 모델에 해당하는 무엇인가를 가졌는가?

■ 월드 모델의 정의

- 세상의 작동에 대한 내적 모델 (Internal models of how the world works [LeCun2022])
- 외부 세계의 동역학을 에이전트 내부에서 추상적으로 표현하고 예측하는 계산 모델 (Internal representation that captures and predicts the dynamics of the external world)

■ 그런데 월드 모델은 무엇인가?

- Internal과 External은? World는? Dynamics는?

[Andreas2024] Jacob Andreas, "Language models, world models, and human model-building," Language&Intelligence@MIT Blog.

[LeCun2022] Y. LeCun, "A path towards autonomous machine intelligence," Open Review.


기계의 월드 모델

■ 월드 모델은 어떻게 만드나?

- 세상은 동적이다!
- Spatio-temporal 공간에서 발생하는 동적 정보를 어떻게 표현하고 개입하나?

■ 동적 정보를 처리할 수 있는 강화 학습

- MDP(Markov decision process)에서는 에이전트가 행동(action)을 결정하면, 환경(environment)은 동역학(dynamics)을 이용하여 다음 상태(state)와 보상(reward)을 제공



[Algorithm 1] Generating a trajectory from the environment

Input: MDP environment env and policy network π_θ

Output: a trajectory τ

1. $state = env.reset()$
2. while True
3. $action \sim \pi_\theta(state)$
4. $state1, reward, done = env.step(action)$
5. $state = state1$
6. if done, break

[Algorithm 2] Reinforcement learning for the optimal policy

Input: MDP environment env

Output: optimal policy network π_{θ^*}

1. Initialize the parameters θ of the policy network π_θ
2. while not converged
3. Generate a trajectory τ using [Algorithm 1]
4. Compute loss (or objective) from τ
5. Update θ using an optimizer




[오일석2025] 오일석, 강화 학습, 한빛아카데미.

기계의 월드 모델

■ 강화 학습으로 월드 모델을 만들 수 있나?

- MDP는 과거를 기억하는 능력이 없음
- 세상을 굴리는 동역학(dynamics)은 외부 환경이 관장하고, 동역학은 한 순간의 전환만 담당
 - Judea Pearl의 causal hierarchy에서 Seeing과 Doing만 가능한 셈
 - Reactive 처리에 머뭇

■ Imagining을 모방하는 월드 모델을 에이전트 내부에 어떻게 만들지?



기계의 월드 모델

■ 내부 시뮬레이터로서 월드 모델

- 에이전트 내부에 있는 동역학을 통해 긴 수평선^{long horizon}의 롤아웃^{rollout} 생성
- 이를 통해 계획^{planning}과 리즈닝^{reasoning}의 고차원 지능 발현

■ 내부 시뮬레이터의 세 가지 요구 사항


- 잠복 표현^{latent representation}
 - 불필요한 상세를 제거하여 과업 달성에 필요한 핵심 정보만 표현
 - 멀티모달 데이터를 하나의 벡터로 표현
- Belief 유지
 - 이전 관측과 행동 ($x_{1:t}, a_{1:t-1}$)에 대한 정보를 담고있는 belief
 - 긴 수평선에서 temporal coherence를 유지
- 스토캐스틱 샘플링
 - 상상 속에서 다양한 미래 롤아웃 생성

- 이들 세 특성을 통해 planning과 강건한 의사 결정이 가능해지고, 이를 기반으로 과업 일반화를 달성하는 길이 열림

기계의 월드 모델

■ 왜 월드 모델인가?

- 미래 예측 기능: counterfactual imagining을 통해 롤아웃 생성 가능
 - 가사 로봇 "옷의 어깨 부분을 잡으면 이런 롤아웃을 거쳐 접기 실패"
 - 자율주행 "좌회전 하면 이런 롤아웃을 거쳐 목적지에 가까워짐"
- 미래 예측 기능을 통해 계획, 추론, 리즈닝 수행
 - 많은 롤아웃을 생성하고 평가함으로써 고도의 지능 발휘
- 잠복 공간을 통해 멀티모달을 표현함으로써 과업 일반화 달성
 - 하나의 신경망으로 여러 과업을 수행 또는 같은 설정 (신경망 구조와 하이퍼 매개변수)을 가진 신경망을 과업마다 학습
- 데이터 효율 증대
 - (상세가 배제된) 추상화된 잠복 공간에서 학습함으로써 소량의 데이터로 학습
- 피지컬 AI의 핵심 모듈 (로봇과 자율주행 등)



월드 모델의 설계 공간

■ 월드 모델의 실제 구현은 다양한 형태

- 잠복 공간을 어떻게 구현할 것인가?
- Belief는 어떻게 유지할 것인가?
- 스토캐스틱한 전이를 어떻게 매개변수화할 것인가?
- 의사결정에 롤아웃을 어떻게 활용할 것인가?
- ...

■ 동역학을 명시적으로 학습할 것인가,를 중심으로 명시적 월드 모델과 암시적 월드 모델로 구분

- 명시적 월드 모델 explicit world model
 - 다음 상태로 전이하는 동역학을 명시적으로 학습
 - 동역학 중심
- 암시적 월드 모델 implicit world model
 - 동역학이 암시적으로 동작함
 - 세상의 지식을 학습하는 표현 학습 중심




초창기 월드 모델:

Ha-Schmidhuber의 월드 모델

강화 학습의 특성과 한계


■ 강화 학습을 다시 살펴보면,

- 예) Gymnasium 라이브러리가 제공하는 CarRacing 과업
 - 상태(state): 96x96 RGB 영상
 - 행동(action): steering(0), gas(1), braking(2)
- 궤적 생성 코드



```
1 env=gym.make('CarRacing-v3', ...) # 과업 설정
2 state=env.reset() # 초기 상태
3 while True:
4     action=agent.policy(state) # 에이전트는 정책을 가지고 행동을 선택
5     state1,reward,done=env.step(action) # 환경의 동역학으로 다음 상태 전이
6     state=state1 # 다음 순간으로 넘어감
7     if done: break # 종료 상태면 탈출
```

- 학습 알고리즘은 랜덤에 가까운 정책 $\pi_{\theta_{random}}(a|s)$ 를 가지고 출발해서, 역전파 개선을 통해 최적에 가까운 정책, $\pi_{\theta_{optimal}}(a|s)$ 에 도달



■ 한계

- 모든 변수가 실제 공간에 표현되기 때문에, 과업 일반화 어렵고 데이터 비효율 발생
- 과거 또는 지식을 기억하는 능력 없음



■ Ha-Schmidhuber 월드 모델은 어떻게 이런 한계를 극복하나?

Ha-Schmidhuber의 에이전트 구조

■ 세 개의 모듈로 구성되는 에이전트 [Ha2018]

- 실제 세계의 영상을 잠복 공간^{latent space} 표현으로 변환하는 인코더 모듈 V
- RNN을 통해 과거를 기억하는 모듈 M
- V와 M이 제공하는 정보를 통해 행동을 선택하는 모듈 C (정책 π 에 해당)

■ V와 M이 월드 모델에 해당



에이전트 구조

■ V 모듈

- 실제 세계에서 본 것을 잠복 공간(latent space), 즉 추상 표현으로 변환하는 역할
- 과업 달성에 불필요한 상세 내용을 제거하고 핵심 정보를 추출하여 잠복 벡터 z 에 표현
 - 잠복 벡터 z 의 차원은 작음 (실험에서는 96x96 영상을 $|z| = 32 \sim 64$ 로 변환)
- VAE (variational autoencoder)로 구현
 - 랜덤 정책으로 생성한 관찰(비디오 프레임)을 훈련 집합으로 사용하여 학습





Figure 5. Flow diagram of a Variational Autoencoder (VAE).

에이전트 구조

■ M 모듈

- 현재 순간까지 벌어진 일을 기억하고, 미래를 예측하는 역할
- RNN과 MDN (mixture density network)을 결합한 MDN-RNN으로 구현
- MDN-RNN은 순간 $t-1$ 에서 $a_{t-1}, z_{t-1}, h_{t-1}$ 를 입력으로 받아 h_t 를 계산하고, h_t 로 부터 가우시안 혼합 ($\alpha_i, \mu_i, \sigma_i$), $i = 1:k$ 를 추정하고, 가우시안 혼합에서 z_t 를 샘플링



에이전트 구조

■ C 모듈

- 기대 이득을 최대화하는 행동을 결정하는 역할 (정책 π 에 해당)
- 월드 모델에 비해 아주 단순한 구조 사용 (W_c 와 b_c 는 최적화해야 할 매개변수)

$$a_t = W_c [z_t \ h_t] + b_c$$

- 예) CarRacing 과업을 위한 매개변수 개수

MODEL	PARAMETER COUNT
VAE	4,348,547
MDN-RNN	422,368
CONTROLLER	867

- W_c 와 b_c 를 최적화하는 학습은 CMA-ES (covariance-matrix adaptation evolution strategy)를 사용

전체 구조

■ 통합 모델과 롤아웃 생성 코드

- 왼쪽 그림은 V, M, C 모듈을 통합한 모델
- 오른쪽 rollout 함수는 잠복 공간에서 롤아웃 하나를 생성




Figure 8. Flow diagram of our Agent model. The raw observation is first processed by V at each time step t to produce z_t . The input into C is this latent vector z_t concatenated with M's hidden state h_t at each time step. C will then output an action vector a_t for motor control, and will affect the environment. M will then take the current z_t and action a_t as an input to update its own hidden state to produce h_{t+1} to be used at time $t + 1$.

```
def rollout(controller):  
    ''' env, rnn, vae are '''  
    ''' global variables '''  
    obs = env.reset()  
    h = rnn.initial_state()  
    done = False  
    cumulative_reward = 0  
    while not done:  
        z = vae.encode(obs)  
        a = controller.action([z, h])  
        obs, reward, done = env.step(a)  
        cumulative_reward += reward  
        h = rnn.forward([a, z, h])  
    return cumulative_reward
```

학습 과정과 실험

■ CarRacing 과업에 대한 학습과 실험

학습 과정:

1. Collect 10,000 rollouts from a random policy.
2. Train VAE (V) to encode frames into $z \in \mathcal{R}^{32}$.
3. Train MDN-RNN (M) to model $P(z_{t+1} \mid a_t, z_t, h_t)$.
4. Define Controller (C) as $a_t = W_c [z_t \ h_t] + b_c$.
5. Use CMA-ES to solve for a W_c and b_c that maximizes the expected cumulative reward.






Figure 10. Despite losing details during this lossy compression process, latent vector z captures the essence of each image frame.

METHOD	AVG. SCORE
DQN (PRIEUR, 2017)	343 $\pm$ 18
A3C (CONTINUOUS) (JANG ET AL., 2017)	591 $\pm$ 45
A3C (DISCRETE) (KHAN & ELIBOL, 2016)	652 $\pm$ 10
CEOBILLIONAIRE (GYM LEADERBOARD)	838 $\pm$ 11
V MODEL	632 $\pm$ 251
V MODEL WITH HIDDEN LAYER	788 $\pm$ 141
FULL WORLD MODEL	906 $\pm$ 21


Table 1. CarRacing-v0 scores achieved using various methods.

무엇을 얻었나?

■ 강화 학습의 MDP와 Ha-Schmidhuber 월드 모델의 비교




- 에이전트는 내부에 월드 모델을 가짐으로써 상상 (잠복 공간) 속에서 동작하는 능력을 갖추



무엇을 얻었나?

- 디플로이 단계를 잠복 공간 (상상의 세계)에서 수행
 - rollout_deploy 함수의 동작




무엇을 얻었나?

■ 직접적 효과

- 데이터 효율 향상
- 과업 수행 성능 향상
- 과업 일반성 향상

■ 한계

- 인코더가 $z_t \sim q_{\phi_E}(z_t|x_t)$ 인 월드 모델로서, 불완전한 belief를 유지하는 셈
- 상태는 잠복 공간에 표현하지만, 행동과 보상은 실제 세계에서 표현
- $V \rightarrow M \rightarrow C$ 를 순차적으로 학습 (통째 학습이 아님)



■ Ha-Schmidhuber 모델은 원시적이지만, 최신 월드 모델을 이해하는 초석



최신 월드 모델

월드 모델 간략 역사

■ 시대 구분

- ~2018 (태동기): 초창기 Ha-Schmidhuber 월드 모델
- 2018~ (성장기): MuZero, Dreamer, Sora, Genie, JEPA 등의 최신 월드 모델이 등장
- 2023~ (LLM 월드 모델 시대): GPT, Gemini 등을 월드 모델로 활용
- 2024~ (피지컬 AI와 결합): 로봇, 자율주행 등 물리적 환경으로 확장

■ 명시적 월드 모델 vs. 암시적 월드 모델

- 명시적^{explicit} 월드 모델
 - 환경의 동역학을 직접 학습
 - Ha-Schmidhuber, MuZero, Dreamer 등
- 암시적^{implicit} 월드 모델
 - 동역학을 명시적으로 학습하지 않은 채, 암시적으로 세상에 대한 지식을 학습
 - 그 자체로는 동역학이 없는데, SFT(supervised fine-tuning)를 통해 동역학 확보
 - LLM, Sora, Genie, JEPA 등

월드 모델에 대한 문헌

■ 월드 모델 서베이 논문

- [Ding2025] J. Ding et al., "Understanding world or predicting future? A comprehensive survey of world models," ACM Computing Surveys.
- [Kong2025] L. Kong et al., "3D and 4D world modeling: a survey," arXiv:2509.07996v2.
- [Zhu2024] Z. Zhu et al., "Is Sora a world simulator? A comprehensive survey on general world models and beyond," arXiv:2405.03520.

■ 월드 모델 기반 피지컬 AI 서베이 논문

- [Fung2025] P. Fung et al. (Meta AI Research), "Embodied AI agents: modeling the world," arXiv:2506.22355v3.
- [Shang2025] Y. Shang et al., "A survey of embodied world models," Open Access.
- [Feng2025] T. Feng et al., "A survey of world models for autonomous driving," arXiv:2501.11260v3.
- [Liu2025] Y. Liu et al., "Aligning cyber space with physical world: a comprehensive survey on embodied AI," IEEE/ASME Transactions on Mechatronics.
- [Liu2025] D. Liu et al., "Generative physical AI in vision: a survey," arXiv:2501.10928v2.
- [Kawaharazuka2025] K. Kawaharazuka et al., "Vision-language-action models for robotics: a review towards real-world applications," IEEE Access.
- [Li2025] X. Li et al., "A comprehensive survey on world models for embodied AI," arXiv:2510.16732.
- [Guan2024] Y. Guan et al., "World models for autonomous driving: an initial survey," IEEE Transactions on Intelligent Vehicles.
- ...

월드 모델에 대한 뜨거운 관심



Workshop Scope

The concept of the "World Model" focuses on how intelligent agents can understand and model the external interactive worlds/environments to improve their decision-making and planning abilities. Over the past two years, the notion of a world model has undergone both conceptual clarification and significant scaling. Moving beyond a loose idea of "models that can imagine the future in the world", increasingly framed as scalable engines for modeling and simulating dynamic interactions with the world, positioned at the intersection of generative modeling, sequential decision-making, multimodal representation learning, simulation and interaction, causal robustness, and spatial intelligence. In practice, contemporary world models learn composable dynamics, often primarily from large-scale video and related multimodal data, and expose interfaces for prediction, planning, and behavior learning.

①





Dreamer

개요

■ Dreamer 시리즈

- PlaNet (deep planning network)이 원조 [Hafner2019]
 - PlaNet은 RSSM을 월드 모델, MPC (model-predictive control)를 planning 알고리즘으로 사용
- PlaNet → Dreamer v1 → Dreamer v2 → Dreamer v3 → Dreamer v4
- Dreamer는 PlaNet의 MPC를 actor-critic으로 대체한 모델
 - 명시적으로 정책 신경망 (actor)을 가지고 있기 때문에, 한번의 신경망 계산으로 행동을 결정할 수 있음
- 버전이 업그레이드되면서 속은 복잡해지고 걷은 단순해짐
 - 에이전트의 내부에 있는 월드 모델은 이산 잠복 상태 도입과 exploration 개선 (v2), critic 규제, value scaling, KL balancing, gradient clipping, dynamics loss balancing 등 (v3)으로 복잡해짐
 - 과업에 따른 하이퍼 매개변수 설정은 단순해짐

(Planet) [Hafner2019] Danijar Hafner et al., "Learning latent dynamics for planning from pixels," ICML.

(Dreamer v1) [Hafner2020] Danijar Hafner et al., "Dream to control: learning behaviors by latent imagination," ICLR.

(Dreamer v2) [Hafner2021] Danijar Hafner et al., "Mastering Atari with discrete world models," ICLR.


(Dreamer v3) [Hafner2023] Danijar Hafner et al., "Mastering diverse domains through world models," arXiv:2301.04104v4 (Nature, 2025).

(Dreamer v4) [Hafner2025] Danijar Hafner et al., "Training agents inside of scalable world models," arXiv:2509.24527.

RSSM

■ 월드 모델을 구현하는 RSSM (recurrent state-space model)


- RSSM = RNN (결정론) + SSM (스토캐스틱)
- RNN은 장기 기억 능력 (안정성), SSM은 불확실성을 통해 다양한 미래 궤적을 생성하는 능력 (풍부한 상상력) 부여



Dreamer v3

■ 월드 모델 (RSSM) 학습

- 6개 헤드를 가진 w_ϕ 신경망



Sequence model:	$h_t = f_\phi(h_{t-1}, z_{t-1}, a_{t-1})$	RNN (GRU)
Encoder:	$z_t \sim q_\phi(z_t h_t, x_t)$	Conv+FC
Dynamics predictor:	$\hat{z}_t \sim p_\phi(\hat{z}_t h_t)$	FC
Reward predictor:	$\hat{r}_t \sim p_\phi(\hat{r}_t h_t, z_t)$	FC
Continue predictor:	$\hat{c}_t \sim p_\phi(\hat{c}_t h_t, z_t)$	FC
Decoder:	$\hat{x}_t \sim p_\phi(\hat{x}_t h_t, z_t)$	MLP+DeConv

=는 deterministic

~는 stochastic

p 는 prior (prediction)

q 는 posterior (observation을 보고 숨겨진 상태를 추정하는 inference)

Dreamer v3

■ 월드 모델 학습

- 세 항을 가진 손실 함수 $\mathcal{L}(\phi)$
 - 예측 손실 함수 $\mathcal{L}_{\text{pred}}$: 실제 공간에서의 관측을 잘 예측하도록 유도
 - 동역학 손실 함수 $\mathcal{L}_{\text{dyn}}$: 잠복 공간의 동역학이 다음 잠복 상태를 잘 예측하도록 유도
 - 표현 손실 함수 $\mathcal{L}_{\text{rep}}$: 잠복 공간이 좋은 표현을 하도록 유도

$$\mathcal{L}(\phi) \doteq E_{q_\phi} \left[\sum_{t=1}^T (\beta_{\text{pred}} \mathcal{L}_{\text{pred}}(\phi) + \beta_{\text{dyn}} \mathcal{L}_{\text{dyn}}(\phi) + \beta_{\text{rep}} \mathcal{L}_{\text{rep}}(\phi)) \right]$$

$$\mathcal{L}_{\text{pred}}(\phi) \doteq -\log p_\phi(x_t|z_t, h_t) - \log p_\phi(r_t|z_t, h_t) - \log p_\phi(c_t|z_t, h_t)$$

$$\mathcal{L}_{\text{dyn}}(\phi) \doteq \max(1, \text{KL}[\text{sg}(q_\phi(z_t|h_t, x_t)) \| p_\phi(z_t|h_t)])$$

$$\mathcal{L}_{\text{rep}}(\phi) \doteq \max(1, \text{KL}[q_\phi(z_t|h_t, x_t) \| \text{sg}(p_\phi(z_t|h_t))])$$

Dreamer v3


■ Actor-critic 학습

■ 신경망 구조

• Actor $a_t \sim \pi_\theta(a_t|s_t)$

• Critic $v_\psi(R_t|s_t)$

(상태 $s_t = [h_t, z_t]$)



■ 손실 함수

$$\mathcal{L}(\psi) \doteq - \sum_{t=1}^T \ln p_\psi(R_t^\lambda | s_t)$$

$$R_t^\lambda \doteq r_t + \gamma c_t((1-\lambda)v_t + \lambda R_{t+1}^\lambda)$$

$$R_T^\lambda \doteq v_T$$

$$\mathcal{L}(\theta) \doteq - \sum_{t=1}^T \text{sg}((R_t^\lambda - v_t)/\max(1, S)) \log \pi_\theta(a_t | s_t) + \eta H[\pi_\theta(a_t | s_t)]$$

Dreamer v3

■ Dreamer 학습 알고리즘

[Algorithm] Concurrent learning of world model and actor-critic

Input: MDP environment env

Output: trained policy network π_{θ_*}

1. Initialize replay buffer $\mathcal{D}$
2. Initialize the parameters ϕ, θ, ψ of the world model, actor, and critic, respectively
3. while not converged
 4. Collect a real trajectory τ by executing π_{θ} with belief states inferred from real observations
 5. Add τ to the replay buffer $\mathcal{D}$ and sample minibatch B from $\mathcal{D}$
 6. Compute loss $\mathcal{L}(\phi)$ and gradients from B , and update ϕ // training world model
 7. Generate an imaginary rollout $\tilde{\tau}$ using the rollout generation algorithm
 8. Compute loss $\mathcal{L}(\psi)$ and gradients from $\tilde{\tau}$, and update ψ // training critic
 9. Compute loss $\mathcal{L}(\theta)$ and gradients from $\tilde{\tau}$, and update θ // training actor

Dreamer v3

■ 성능

- 'Understand' the environment structure




Fig. 3 | Video predictions of the world model. A procedural maze and a quadrupedal robot are shown. Given 5 context images and the full action sequence of an unseen video, Dreamer predicts 45 frames into the future

without access to intermediate images. From pixel observations, the world model learns an understanding of the underlying structure of each environment.

■ 과업 일반화




Fig. 4 | Benchmark scores. Using fixed hyperparameters across all domains, Dreamer outperforms tuned expert algorithms across a wide range of benchmarks and data budgets. Dreamer also substantially outperforms a

high-quality implementation of the widely applicable PPO algorithm. IMPALA and R2D2+ use ten times more data on DMLab.

Ha-Schmidhuber와 Dreamer의 비교

■ 두 모델의 성능 비교

	Ha-Schmidhuber	Dreamer
State estimation	약함	강함
Uncertainty	약함	강함
Long-horizon	불안정	안정
Policy quality	제한적	우수
Sample efficiency	낮음	높음
Partial observability	대응력 약함	대응력 높음
Task generality	약함	강함



MuZero

개요

■ MuZero 월드 모델은 AlphaGo에서 진화

- AlphaGo [Silver2016]: SL+RL+MCTS
- AlphaGo Zero [Silver2017]: RL+MCTS
- AlphaZero [Silver2018]: Go뿐 아니라 chess와 shogi로 과업 확장
- MuZero [Schrittwieser2020]: 보드 게임뿐 아니라 Atari 비디오 게임으로 과업 확장



■ 근본 원리와 발전 방향

- 이들은 강화 학습을 MCTS와 결합한 모델-기반 강화 학습(MBRL) 알고리즘 (DQN, A2C, PPO, SAC 등의 강화 학습 알고리즘은 모델-자유)
- 과업 특수성을 띤 데이터와 연산을 벗어나서, 멀티모달을 표현하고 다양한 과업 연산을 다룰 수 있는 방향으로 발전
- 특히 MuZero는 상태를 잠복 공간에 표현하는 월드 모델을 학습하고, 월드 모델과 MCTS를 결합하여 미래 예측

[Silver2016] D. Silver et al., "Mastering the game of Go with deep neural networks and tree search," Nature.

[Silver2017] D. Silver et al., "Mastering the game of Go without human knowledge," Nature.

[Silver2018] D. Silver et al., "A general reinforcement learning algorithm that masters chess, shogi, and Go through self-play," Science.

[Schrittwieser2020] J. Schrittwieser et al., "Mastering Atari, Go, and chess and shogi by planning with a learned model," Nature.

[Moerland2023] T.M. Moerland et al., "Model-based reinforcement learning: a survey," Foundations and Trends in Machine learning.

몬테카를로 트리 탐색

■ 트리 탐색 tree search 알고리즘

- 최고 우선 탐색 best-first search, A*, minimax를 거쳐 MCTS (Monte Carlo tree search)로 발전
- Brugmann은 1992년에 몬테카를로 방법을 바둑에 적용
- 2000년 초에는 UCB 공식이 탄생 (몬테카를로 방법의 핵심 연산)
- 2006년에 Coulom은 이들 아이디어를 정리하여 MCTS 알고리즘 발표

■ 기존 트리 탐색 알고리즘과 MCTS의 근본 차이

- 기존 알고리즘은 탐색 깊이를 제한하고 휴리스틱 함수로 리프 노드의 goodness 평가하여 최적 수를 선택
- MCTS는 승패가 결정되는 상태까지 롤아웃 rollout 생성. 빠른 방법으로 충분히 많은 롤아웃을 생성한 다음 통계 기반으로 최적 수를 선택

몬테카를로 트리 탐색

■ MCTS의 원리

- [그림 13-5]는 틱택토를 예제로 사용하여 설명 (①~⑥ 중에서 최적 수를 선택하는 상황)
- 선택→확장→시뮬레이션→역전파 네 단계를 거쳐 선택
- 충분히 많은 롤아웃을 생성한 다음, *visit*이 최대 또는 승률이 최대인 노드를 최적 수로 선택함 (이 예제에서는 노드 ⑤를 선택)




그림 13-5 몬테카를로 트리 탐색의 원리

AlphaGo

■ AlphaGo의 전체 학습 과정

- 흉내 학습 (지도 학습), 강화 학습, MCTS를 순차적으로 적용
- 이들 중 일부만 적용하는 경우 초급 또는 중급 수준까지만 도달




그림 13-6 알파고의 정책 신경망과 가치 신경망, MCTS 학습 과정

AlphaGo Zero

■ 흉내 학습 없이 강화 학습과 MCTS를 결합

- 상태 s_t 는 19x19x3 텐서 (흑, 백, 빈 점만 표시)로 표현 (AlphaGo는 19x19x48 텐서 사용)
- 하나의 신경망 f_θ 만 학습 (AlphaGo는 $p_\pi, p_\sigma, p_\rho, v_\theta$ 를 학습)
- 롤아웃을 생성하지 않는 MCTS 사용 (AlphaGo는 롤아웃 생성)




그림 13-7 알파고 제로가 신경망 f_θ 를 학습하는 과정 [Silver2017]

AlphaGo Zero

■ 신경망 $(p, v) = f_{\theta}(s)$ 학습

- 신경망 f_{θ} 는 상태 s 를 입력으로 받아 행동 a 를 선택할 확률 분포 p 와 가치 (이득) v 출력
- 강화 학습과 MCTS가 동시에 학습 (알파고는 순차적으로 학습)




그림 13-8 알파고와 알파고 제로의 학습 과정 비교

■ 두 단계를 반복하는 학습 알고리즘

- 첫 단계: MCTS로 에피소드 수집
 - 매 순간 f_{θ} 로 행동의 확률 분포 π_t 추정하고, π_t 를 통해 행동 a_t 를 샘플링
 - 이렇게 에피소드 $s_0 - a_0 - s_1 - a_1 - \dots - s_{T-1} - a_{T-1} - s_T$ 를 생성하고 보상 z 결정
- 둘째 단계: f_{θ} 를 학습
 - 매 순간 f_{θ} 로 (p_t, v_t) 계산, (π_t, z) 를 정답으로 손실 함수 계산하고 옵티마이저로 학습

■ AlphaGo를 대상으로 백전백승 (단순함의 힘!)

- AlphaGo Zero는 왜 작동하는가?

AlphaZero

■ AlphaZero는 AlphaGo Zero의 과업 일반화 능력을 확장

- 바둑 뿐만 아니라 다른 보드 게임도 학습할 수 있나?
 - 알파제로는 알파고 제로를 체스와 쇼기로 확장
- AlphaGo Zero에서 바둑에 특화된 두 가지 점을 제거
 - 승/패를 승/패/비김으로 확장
 - 바둑의 대칭성을 이용하여 데이터 증강하던 부분을 제거함
- 과거의 자신 복제품 리스트에서 랜덤 선택하여 자기 대전하던 방식을 현재의 자신 복제품과 자기 대전

■ 성능

- AlphaGo Zero의 신경망 구조와 하이퍼 매개변수를 그대로 가져다 사용
- 학습 시간 단축: 체스 9시간, 쇼기 12시간, 바둑 13일
- 바둑에서 AlphaGo Zero를 상대로 61% 승률

MuZero

■ 보드 게임뿐만 아니라 비디오 게임도 학습할 수 있나?

- MuZero는 AlphaZero를 아타리 비디오 게임으로 확장
- 성질이 근본적으로 다른 두 종류의 과업을 어떻게 하나의 알고리즘으로 학습할까?
 - 게임 방식 뿐 아니라 입출력이 달라, 상태와 행동 공간이 멀티모달
 - 보드 게임은 계획^{planning}을 하는 MCTS, 비디오 게임은 DQN으로 학습하는 근본적 차이

■ MuZero는 월드 모델을 품은 모델-기반 강화 학습 (MBRL) 알고리즘


- 과업 일반화를 위한 해법은 추상화^{abstraction}에 있음
 - 멀티모달을 표현하기 위해 상태를 잠복 공간에 표현
 - 원래 상태 공간은 화면 또는 19x19 보드이기 때문에 해석 가능하지만 잠복 공간은 서로 다른 모달리티가 공유하는 벡터로 표현되기 때문에 해석 불가능

■ MuZero = 월드 모델 (신경망 μ_{θ}) + MCTS 계획


MuZero

■ 전체 학습 과정

- MCTS는 월드 모델 μ_θ 로 충분히 많은 수의 롤아웃을 생성하여 정책 π_t 과 가치 v_t 를 추정한다. 다음, π_t 과 v_t 를 정답으로 활용하여 손실 함수를 계산하고, 옵티마이저로 μ_θ 를 개선하는 과정을 반복



(a) MCTS 과정



(b) 에피소드 생성과 학습 과정

토론

■ MuZero와 Dreamer의 비교

	MuZero	Dreamer
행동 결정	MCTS	신경망(actor)
롤아웃 사용	학습과 추론	학습할 때만
Long-horizon	안정	안정
Sample efficiency	높음	매우 높음
Task generality	강함	매우 강함

■ MuZero의 한계

- 이산 과업에만 적용 가능 → 로봇이나 자율주행 응용에 취약
- 영상을 복원하는 기능이 없음 (Ha-Schmidhuber와 Dreamer는 영상 생성 능력 있음)

■ MuZero의 개선

- EfficientZero는 데이터 효율을 크게 향상하고 연속 과업으로 확장



JEPA

LeCun의 AGI 구조

■ 동기

A self-driving system for cars may require thousands of trials of reinforcement learning to learn that driving too fast in a turn will result in a bad outcome, and to learn to slow down to avoid skidding. By contrast, humans can draw on their intimate knowledge of intuitive physics to predict such outcomes, and largely avoid fatal courses of action when learning a new skill. ...

The answer may lie in the ability of humans and many animals to learn *world models*, internal models of how the world works.


I submit that devising learning paradigms and architectures that would allow machines to learn *world models* in an unsupervised (or self-supervised) fashion, and to use those models to predict, to reason, and to plan is one of the main challenges of AI and ML today. One major technical hurdle is how to devise trainable world models that can deal with complex uncertainty in the predictions. ...

■ 도전

1. How can machines learn to represent the world, learn to predict, and learn to act largely by observation?
2. How can machine reason and plan in ways that are compatible with gradient-based learning?
3. How can machines learn to represent percepts and action plans in a hierarchical manner, at multiple levels of abstraction, and multiple time scales?

LeCun의 AGI 구조

■ 아이의 뇌에 월드 모델이 형성되는 과정



But can a human or animal brain contain all the world models that are necessary for survival? One hypothesis in this paper is that animals and humans have only one world model engine somewhere in their prefrontal cortex. That world model engine is dynamically configurable for the task at hand. With a single, configurable world model engine, rather than a separate model for every situation, knowledge about how the world works may be shared across tasks. This may enable reasoning by analogy, by applying the model configured for one situation to another situation.

LeCun의 AGI 구조

■ 전체 시스템 구조




Figure 2: A system architecture for autonomous intelligence. All modules in this model are assumed to be “differentiable”, in that a module feeding into another one (through an arrow connecting them) can get gradient estimates of the cost’s scalar output with respect to its own output.

The configurator module takes inputs (not represented for clarity) from all other modules and configures them to perform the task at hand.

The perception module estimates the current state of the world.

The world model module predicts possible future world states as a function of imagined actions sequences proposed by the actor.

The cost module computes a single scalar output called “energy” that measures the level of discomfort of the agent. It is composed of two sub-modules, the intrinsic cost, which is immutable (not trainable) and computes the immediate energy of the current state (pain, pleasure, hunger, etc), and the critic, a trainable module that predicts future values of the intrinsic cost.

The short-term memory module keeps track of the current and predicted world states and associated intrinsic costs.

The actor module computes proposals for action sequences. The world model and the critic compute the possible resulting outcomes. The actor can find an optimal action sequence that minimizes the estimated future cost, and output the first action in the optimal sequence.

See Section 3 for details.

The Cost Module as the Driver of Behavior





Figure 6: Architecture of the cost module. The cost module comprises the intrinsic cost module which is immutable $IC_i(s)$ (left) and the critic or Trainable Cost $TC_j(s)$ (right), which is trainable. Both IC and TC are composed of multiple submodules whose output energies are linearly combined. Each submodule imparts a particular behavioral drive in the agent. The weights in the linear combination, u_i and v_j , are determined by the configurator module and allow the agent to focus on different subgoals at different times.


■ JEPA 학습은 SSL (self-supervised learning)로 달성

- 패턴 완성 (pattern completion) 틀에서 EBM (energy-based model)으로 학습
 - 에너지 함수 $F_w(x, y)$ 는 x 와 y 가 연관성이 있는 경우 낮은 에너지 값, 연관성 없는 경우 높은 에너지 값 부여
- 잠복 변수 z 를 도입하여 x 를 y 로 변환하는데 중요한 역할을 하는 정보를 표현
 - 자율주행의 경우, z 는 내 차의 행동, 다른 차의 행동, 보행자와 신호등 변화 등을 표현
 - 강화 학습의 행동 변수는 내 차의 행동만 표현 (잠복 변수는 훨씬 포괄적)
 - 잠복 변수를 통해 상상 속에서 다양한 롤아웃 생성 가능 → planning 또는 리즈닝

예1)




예2)



JEPA


■ JEPA의 구조

- JEPA는 Generative latent-variable 모델과 JEA 모델을 결합한 모델
 - 잠복 변수 z 를 통해 불확실성 표현
- x 와 y 모두 Enc 적용하여 잠복 공간으로 임베딩
 - x 와 y 의 인코더는 같을 수도 다를 수도 있음. 특히 x 와 y 의 모달리티가 다른 경우에는 다른 인코더 사용해야 함
- 디코더가 없기 때문에 생성 모델이 아님 → 르쿤은 왜 생성 기능을 두지 않았을까?



JEPA

■ H-JEPA (계층적 JEPA)의 구조



I submit that the ability to represent sequences of world states at several levels of abstraction is essential to intelligent behavior. With multi-level representations of world states and actions, a complex task can be decomposed into successively more detailed sub-tasks, instantiated into actions sequences when informed by local conditions. For example, planning a complex task, like commuting to work, can be decomposed into driving to the train station, catching a train, etc. Driving to the train station can be decomposed into walking out of the house, starting the car, and driving. Getting out of the house requires standing up, walking to the door, opening the door, etc. This decomposition descends all the way down to millisecond-by-millisecond muscle controls, which can only be instantiated when the relevant environmental conditions are perceived (obstacles, traffic lights, moving objects, etc).

JEPA

■ JEPA의 구현

- I-JEPA [Assran2023] <https://ai.meta.com/blog/yann-lecun-ai-model-i-jepa/>
- V-JEPA [Bardes2024] <https://ai.meta.com/blog/v-jepa-yann-lecun-ai-model-video-joint-embedding-predictive-architecture/>
- V-JEPA 2 [Assran2025] <https://ai.meta.com/vjepa/> ← 피지컬 AI로 확장 (로봇 적용)
- A-JEPA: 오디오 [Fei2023]
- LLM-JEPA [Huang2025]
- seq-JEPA [Ghaemi2025]
- AD-L-JEPA [Zhu2025]
- ...

[Assran2023] M. Assran et al., "Self-supervised learning from images with a joint-embedding predictive architecture," arXiv:2301.08243v3.

[Bardes2024] A. Bardes et al., "Revisiting feature prediction for learning visual representations from video," arXiv:2404.08471v1.

[Assran2025] M. Assran et al., "V-JEPA 2: self-supervised video models enable understanding, prediction and planning," arXiv:2506.09985v1.

[Fei2023] Z. Fei et al., "A-JEPA: joint-embedding predictive architecture can listen," arXiv:2311.15830.

[Huang2025] H. Huang et al., "LLM-JEPA: large language models meet joint embedding predictive architecture," arXiv:2509.14252v2.

[Ghaemi2025] H. Ghaemi et al., "seq-JEPA: autoregressive predictive learning of invariant-equivalent world models," arXiv:2505.03176.

[Zhu2025] Haoran Zhu et al., "Self-supervised representation learning with joint embedding predictive architecture for automotive LiDAR object detection," arXiv:2501.04969v2.




I-JEPA

■ JEPA의 구현

- JEPA 틀 $\rightarrow$ I-JEPA (영상에 구현) $\rightarrow$ V-JEPA (비디오에 구현) $\rightarrow$ V-JEPA 2 (피지컬 AI)

■ I-JEPA [Assran2023]


- JEPA와 masked image 기법을 결합한 SSL
- 특징 예측 (feature prediction)에 의한 성능 향상
 - 임베딩 공간에서 특징의 의미 표현력 향상



V-JEPA

■ V-JEPA [Bardes2024]


- I-JEPA를 비디오로 확장
- ViT 트랜스포머로 구현



V-JEPA

■ 성능 향상

- 추론: 인코더를 frozen시킨 채, attentive probing을 통해 하위 과업으로 전이
- 데이터셋: HowTo100M + Kinetics 400/600/700 + Something-Something-v2



- Low-shot 실험으로 label-efficiency 입증

		Frozen Evaluation					
		K400 (16×8×3)			SSv2 (16×2×3)		
Method	Arch.	5% (~29 samples per class)	10% (~58 samples per class)	50% (~287 samples per class)	5% (~48 samples per class)	10% (~96 samples per class)	50% (~440 samples per class)
MVD	ViT-L/16	62.6 ± 0.2	68.3 ± 0.2	77.2 ± 0.3	42.9 ± 0.8	49.5 ± 0.6	61.0 ± 0.2
VideoMAE	ViT-H/16	62.3 ± 0.3	68.5 ± 0.2	78.2 ± 0.1	41.4 ± 0.8	48.1 ± 0.2	60.5 ± 0.4
VideoMAEv2	ViT-g/14	37.0 ± 0.3	48.8 ± 0.4	67.8 ± 0.1	28.0 ± 1.0	37.3 ± 0.3	54.0 ± 0.3
V-JEPA	ViT-H/16	67.0 ± 0.2	72.1 ± 0.1	80.2 ± 0.2	51.9 ± 0.3	57.5 ± 0.4	67.3 ± 0.2
	ViT-H/16 ₃₈₄	68.2 ± 0.2	72.8 ± 0.2	80.6 ± 0.2	54.0 ± 0.2	59.3 ± 0.5	67.9 ± 0.2



Genie

개요

■ Genie [Bruce2024]

- "*generative interactive environment* trained in an unsupervised manner from unlabeled Internet videos, prompted to generate an endless variety of action-controllable virtual worlds described through text, synthetic images, photographs, and even sketches"




- Action 정보가 없는 비디오 데이터로 학습

Model Class	Training Data	Controllability
World Models	Video + Actions	Frame-level
Video Models	Video + Text	Video-level
Genie	Video	Frame-level

← Action 정보 없이 학습했는데,
어떻게 frame-level 제어가 가능할까?

구조

- Genie는 spatial-temporal (ST) transformer로 구현




- 시간 효율 향상
 - 기존 트랜스포머: $O((WHT)^2)$
 - ST 트랜스포머: $O(T(WH)^2 + HW(T)^2)$
- 정확도 성능 향상

구조


■ 세 개의 구성요소

- 이들 모두 ST 트랜스포머로 구현



■ 잠복 행동 모델 (LAM)

- 인터넷 비디오에는 행동 (action) 정보가 없음 → SSL로 잠복 행동을 학습




- VQ-VAE의 목적 함수 사용 (실험에서는 행동의 종류를 8로 제한)
- 추론 단계에서 사용자는 해석 불가능한 잠복 행동을 어떻게 입력할까?

실험

■ 두가지 환경에서 실험

- Platformer 게임 비디오
- RT1 로봇 비디오 (이 데이터는 action 정보를 가지고 있는데, 이를 배제하고 학습)



■ Genie는 토대 월드 모델인가?

- “We believe that this shows our approach presents a path to using larger video datasets from the Internet to create a foundation world model for robotics.”
- “We believe Genie could one day be used as a foundation world model for training generalist agents.”

■ Genie는 Genie 2 (3D 비디오), Genie 3으로 발전

	GameNGen	Genie 2	Veo	Genie 3
Resolution	320p	360p	720p to 4K	720p
Domain	Game-specific	3D Environments	General	General
Control	Game-specific	Limited keyboard / mouse actions	Video-level description*	Navigation; Promptable world events
Interaction Horizon	A few seconds	10-20 seconds	8 seconds	Multiple minutes
Interaction Latency	Real time	Not real time	N/A	Real time

[Parker-Holder2024] J. Parker-Holder et al., “Genie 2: a large-scale foundation world model,” DeepMind blog.

[Parker-Holder2025] J. Parker-Holder et al., “Genie 3: a new frontier for world models,” DeepMind blog.



피지컬 AI

피지컬 AI란?

■ 정의

- “몸을 가지고 물리 세계와 상호작용하는 AI” (embodied AI that interacts with the physical world)
- “Physical AI lets autonomous systems like cameras, robots, and self-driving cars perceive, understand, reason, and perform or orchestrate complex actions in the physical world.” (<https://www.nvidia.com/en-us/glossary/generative-physical-ai>)

The Definition of Physical AI therefore is: *Physical AI refers to artificial intelligence systems that not only process information and make decisions in the digital space but also interact directly with the physical world and they use sensors to perceive their environment, model dynamic states of the real world, make autonomous decisions on how to act, and implement these decisions using actuators (e.g. robotic arms, driving movements, gripping devices). The aim is to achieve continuous adaptation and learning ability under conditions of uncertainty, limited perception, and physical laws.* [Salehi2025]

피지컬 AI란?

■ 이 튜토리얼은 피지컬 AI를 두 수준으로 구분 ([LeCun2022])

- **반응형** 피지컬 AI (responsive physical AI) "Mode-1"
 - 특정 과업을 위해 규칙 또는 강화 학습으로 만든 모델을 통해 인식과 의사 결정, 행동 사이클을 반응적으로 수행하는 실물 인공지능 (embodied AI fulfilling responsively a cycle of perception, decision-making, and action through rules or learned models for a specific task)
 - 월드 모델 없고, 리즈닝은 낮은 수준이거나 없음
- **월드 모델 기반** 피지컬 AI (world-model-based physical AI) "Mode-2"
 - 월드 모델을 통해 상상 속에서 미래를 예측할 수 있으며 고도의 리즈닝을 통해 다양한 과업을 수행할 수 있는 실물 인공지능 (embodied AI fulfilling a diversity of tasks through high-level reasoning and predicting futures through world models)
 - 월드 모델이 핵심 역할을 수행하며, 고도의 리즈닝 기능을 갖추
 - 미래 예측 사례
 - "책상 위의 노란 공을 2.4의 힘으로 굴리면 책상 위에 머물 확률 0.84, 아래로 떨어질 확률 0.16"



System 1 operates automatically and quickly, with little or no effort and no sense of voluntary control.

17x24 계산

System 2 allocates attention to the effortful mental activities that demand it, including complex computations. The operations of System 2 are often associated with the subjective experience of agency, choice, and concentration.

서베이 글

■ 피지컬 AI 서베이 논문

- [Thakur2025] A. Thakur et al., "Physical AI for powering the next revolution in robotics," J. of Computing and Information Science in Engineering.
- [Salehi2025] Vahid Salehi, "Fundamentals of physical AI," arXiv:2511.09497.
- [Fung2025] P. Fung et al. (Meta AI Research), "Embodied AI agents: modeling the world," arXiv:2506.22355v3.
- [Shang2025] Y. Shang et al., "A survey of embodied world models," Open Access.
- [Feng2025] T. Feng et al., "A survey of world models for autonomous driving," arXiv:2501.11260v3.
- [Liu2025] Y. Liu et al., "Aligning cyber space with physical world: a comprehensive survey on embodied AI," IEEE/ASME Transactions on Mechatronics.
- [Liu2025] D. Liu et al., "Generative physical AI in vision: a survey," arXiv:2501.10928v2.
- [Kawaharazuka2025] K. Kawaharazuka et al., "Vision-language-action models for robotics: a review towards real-world applications," IEEE Access.
- [Li2025] X. Li et al., "A comprehensive survey on world models for embodied AI," arXiv:2510.16732.
- [Guan2024] Y. Guan et al., "World models for autonomous driving: an initial survey," IEEE Transactions on Intelligent Vehicles.
- [Allgood2025] Kiva Allgood and Daniel Kuepper, "Physical AI: powering the new age of industrial operations," White paper by World Economic Forum.

■ 블로그 포스트

- <https://www.nvidia.com/en-us/glossary/generative-physical-ai>
- <https://encord.com/blog/physical-ai/>


반응형 피지컬 AI

■ 낮은 수준



■ SOTA 수준


- 민첩한 휴머노이드 로봇 (CMU&NVIDIA) [He2025]
 - 선수들의 민첩한 행동을 PPO 알고리즘으로 학습
 - Delta action 모델을 통한 정교한 sim2real 구현
 - Unitree G1 로봇에서 구현
- 탁구 로봇 (DeepMind) [D'Ambrosio2024]
 - LLC 정책과 HLC 정책을 BGS 알고리즘으로 학습
 - 상대의 플레이 성향을 파악하여 대응
 - ABB 110 매니퓰레이터 로봇에서 구현



반응형 피지컬 AI

■ SOTA 수준

- 휴머노이드 탁구 로봇 (UC, Berkeley) [Su2025]
 - Asymmetric actor-critic 알고리즘으로 전략 학습
 - Unitree G1 로봇에서 구현
- 민첩한 초소형 비행 곤충 로봇 (MIT) [Hsiao2025]
 - 급정거, 사카드^{saccade} 기동, 뒤집기 등이 가능
 - 딥러닝과 MPC의 결합
- 컬리 (고려대학교) [Won2020]
 - 높은 불확실성의 얼음판에서 정교한 공 조절
 - 자체 제작 로봇에서 구현



[He2025] Tairan He et al., "ASAP: aligning simulation and real-world physics for learning agile humanoid whole-body skills," arXiv:2502.01143v2.

[D'Ambrosio2024] David B. D'Ambrosio et al., "Achieving human level competitive robot table tennis," arXiv:2408.03906v2.

[Su2025] Z. Su et al., "HITTER: a humanoid table tennis robot via hierarchical planning and learning," arXiv:2508.21043v2.

[Hsiao2025] Y.H. Hsiao et al., "Aerobatic maneuvers in insect-scale flapping-wing aerial robots via deep-learned robust tube model predictive control," Science Advances.

[Won2020] D.-O. Won et al., "An adaptive deep reinforcement learning framework enables curling robots with human-like performance in real-time conditions," Science Robotics.

민첩한 휴머노이드 로봇

■ ASAPaligning simulation and real-world physics (CMU&NVIDIA) [He2025]

- 사람의 민첩한 동작(골 세레머니, 덩크 슛 등)을 정교하게 흉내 내는 로봇



- 비디오로 배우는 두 단계 강화 학습. Delta action 모델을 학습하여 sim2real 해결







그림 13-22 ASAP 로봇의 두 단계 학습 과정[He2025]

월드 모델 기반 피지컬 AI

- 월드 모델과 결합하여 AGI를 추구하는 피지컬 AI





월드 모델 기반 피지컬 AI: DayDreamer

[Wu2022] P. Wu et al., "DayDreamer: world models for physical robot learning," arXiv:2206.14176v1.

개요

■ DayDreamer는 Dreamer를 로봇에 응용한 초창기 월드 모델 기반 로봇 I

■ 실험 목적

- Does Dreamer enable robot learning directly in the real world, without simulators?
 - Does Dreamer succeed across various robot platforms, sensory modalities, and action spaces?
 - How does the data-efficiency of Dreamer compare to previous reinforcement learning algorithms?
- 네 종류의 로봇에서 다양한 과업을 수행할 수 있게 Dreamer를 학습
- 연속 과업과 이산 과업, 밀집 보상과 희소 보상
 - 멀티 모달리티 입력: proprioceptive 신호, force 신호, RGB 영상, 깊이 영상



(a) A1 Quadruped Walking



(b) UR5 Visual Pick Place




(c) XArm Visual Pick Place



(d) Sphero Navigation


신경망 학습

■ 신경망 구조



■ 전체 학습 파이프라인 (시뮬레이터 없이 로봇과 직접 상호작용하는 온라인 학습)








훈련 데이터는 어디서 오나?



- 월드 모델 RSSM과 actor-critic 학습은 Dreamer v2 활용
- 동일한 신경망 구조와 동일한 하이퍼 매개변수 사용

성능 실험

- 훨씬 적은 데이터를 사용하여 더 좋은 성능 달성



과업 일반화 향상
(동일하게 설정된 신경망으로
네 개 과업을 학습)



V-JEPA 2

[Assran2025] M. Assran et al., "V-JEPA 2: self-supervised video models enable understanding, prediction and planning," arXiv:2506.09985.

V-JEPA 2 개요

■ V-JEPA 2

- V-JEPA를 로봇에 적용함으로써 피지컬 AI로 확장





Figure1 V-JEPA 2 Overview. Leveraging 1M hours of internet-scale video and 1M images, we pretrain the V-JEPA 2 video model using a visual mask denoising objective (Bardes et al., 2024; Assran et al., 2023), and leverage this model for downstream tasks such as action classification, object recognition, action anticipation, and Video Question Answering by aligning the model with an LLM backbone. After pretraining, we can also freeze the video encoder and train a new action-conditioned predictor with a small amount of robot interaction data on top of the learned representations, and leverage this action-conditioned model, V-JEPA 2-AC, for downstream robot manipulation tasks using planning within a model predictive control loop.

규모 확장

■ V-JEPA를 scaling하여 V-JEPA 2를 학습


1. *Data scaling*: We increase the dataset size from 2 million to 22 million videos by leveraging and curating additional data sources.
2. *Model scaling*: We scale the encoder architecture from 300 million to over 1 billion parameters, going from a ViT-L to a ViT-g (Zhai et al., 2022).
3. *Longer training*: Adopting a warmup-constant-decay learning rate schedule simplifies hyperparameter tuning and enables us to extend training from 90 thousand up to 252 thousand iterations, effectively leveraging the additional data.
4. *Higher resolution*: We leverage the warmup-constant-decay schedule to efficiently scale to higher resolution video and longer video clips by training on shorter, lower-resolution clips during the warmup and constant phases, and then increasing resolution and/or clip-length during the final decay phase.




학습

■ V-JEPA 2-AC

- Pre-train된 V-JEPA 2를 V-JEPA 2-AC (action-conditioned)로 전이
 - “Learn a frame-causal action-conditioned predictor”
 - 전이 학습은 Franka Panda 로봇에서 Droid 데이터셋을 이용하여 수행
 - 인코더는 frozen시키고, predictor를 학습



$$\text{minimize}_{\theta, \phi, \Delta_y} \|P_{\phi}(\Delta_y, E_{\theta}(x)) - \text{sg}(E_{\bar{\theta}}(y))\|_1$$




Droid 데이터셋

데이터

■ DROID 데이터

- Action 레이블링이 안된 3~4초 비디오를 teleoperation으로 제작
- 프레임마다 end-effector 상태를 표시한 7차원 벡터 (위치 3+방향 3+그리퍼 1)가 있음

■ V-JEPA 2-AC 미세 조정에는 62시간 분량을 추출하여 사용



실험

■ 성능 실험

- 비교 대상: VLA 모델인 Octo와 비디오 생성 모델인 Cosmos
- 두 종류의 과업: single-goal reaching과 prehensile manipulation



Table 2 Zero-Shot Robot Manipulation

Method			Grasp		Reach w/ Obj.		Pick-&-Place	
			Cup	Box	Cup	Box	Cup	Box
Octo (Octo Model Team et al., 2024)	Lab 1	100%	20%	0%	20%	70%	20%	10%
	Lab 2	100%	10%	0%	10%	70%	10%	10%
	Avg	100%	15%	0%	15%	70%	15%	10%
V-JEPA 2-AC (ours)	Lab 1	100%	70%	30%	90%	80%	80%	80%
	Lab 2	100%	60%	20%	60%	70%	80%	50%
	Avg	100%	65%	25%	75%	75%	80%	65%



Gemini Robotics

[GeminiRobotics2025] Gemini Robotics team, "Gemini Robotics: bringing AI into the physical world," arXiv:2503.20020v1.

VLA 로봇

■ 지능 로봇이 AGI에 한 발짝 다가가려면 어떻게 해야할까?

- 다양한 환경에서 다양한 과업을 수행할 수 있어야 하고 과업 사이의 전이가 무봉^{seamless}으로 이루어져야 함
- LLM은 AGI에 가장 근접한 모델로 평가됨. LLM을 로봇에 활용할 수 있을까?
- LLM은 SFT를 통해 다양한 하위 과업(질의 응답, 표 예매 등)으로 전이 가능
- LLM에서 로봇 과업을 하위 과업으로 간주하여 SFT를 적용할 수 있을까? → 이렇게 제작한 모델을 VLA (vision-language-action) 모델이라고 부름



Dexterous, general & instructable Vision-Language-Action model




Complex dexterous tasks



New embodiments



Advanced embodied reasoning for robotics



Advanced reasoning & acting



VLA 서버이:

[Kawaharazuka2025] K. Kawaharazuka et al., "Vision-language-action models for robotics: a review towards real-world application," IEEE Access.

[Ma2024] Y. Ma et al., "A survey on vision-language-action models for embodied AI," arXiv:2405.14093v5.

[Firoozi2023] R. Firoozi et al., "Foundation models in robotics: applications, challenges, and the future," arXiv:2312.07843.


VLA 로봇

■ 구글의 지능 로봇 연구

- SayCan: Gemini 응답을 재정렬하여 로봇 제어에 유리한 응답이 1순위 되도록 강화 학습으로 재정렬. 비디오 처리를 CNN으로 구현
- RT-1: SayCan의 CNN을 트랜스포머로 변경
- RT-2: PaLI-X와 PaLM-E의 VLM을 SFT 학습
- RT-X: 대용량 데이터셋 Open X-Embodiment로 학습
- Gemini Robotics: LLM으로 Gemini 채택하고 보다 체계적으로 학습

■ Open X-Embodiment [Padalkar2023]

- 현재 가장 방대한 로봇 데이터셋 (21개 기관의 컨소시움)



Open X-Embodiment

구성요소

■ 구성요소

- ERQA: 실물 리즈닝^{embodied reasoning}, ER을 평가하기 위한 벤치마킹 다지선다형 문제 은행
- Gemini Robotics ER: 실물 리즈닝 기능이 강화된 VLM
- Gemini Robotics: 다양한 로봇 과업에 대해 로봇 행동을 생성할 수 있는 VLA

■ ERQA

- QA 사례

Trajectory Reasoning	Action Reasoning	Spatial Reasoning
 Approximately which colored trajectory should the zipper follow to begin zipping up the suitcase? A. Blue B. Purple C. Green D. Red	 How should the person move the wrench so that it is ready to rotate the hex screw closest to it? A. Forward and right B. Up and left C. Forward and left D. None of the above	 There are 4 sinks in the picture. Which arrow points to the one that is closest to the viewer? A. Cyan B. Blue C. Red D. None of the arrows

- 성능




Benchmark	Gemini				GPT		Claude
	1.5 Flash	1.5 Pro	2.0 Flash	2.0 Pro Experimental	4o-mini	4o	3.5 Sonnet
ERQA	42.3	41.8	46.3	48.3	37.3	47.0	35.5
RealworldQA (test)	69.0	64.5	71.6	74.5	65.0	71.9	61.4
BLINK (val)	59.2	64.4	65.0	65.2	56.9	62.3	60.2

Prompt Variant	Gemini		GPT		Claude
	2.0 Flash	2.0 Pro Experimental	4o-mini	4o	3.5 Sonnet
Without CoT	46.3	48.3	37.3	47.0	35.5
With CoT	50.3	54.8	40.5	50.5	45.8

구성요소

■ Gemini Robotics ER


- ER: 'the ability of VLM to ground objects and spatial concepts in the real world, and the ability to synthesize signals for downstream robotic applications'
- Gemini Robotics ER은 Gemini의 ER 능력을 SFT로 향상한 VLM
 - 검출, 포인팅, 궤적 예측 (flash 버전), 그리핑 등



- 3D 공간 리즈닝: 다중-시점 correspondence, 3D 검출



Detect the 3D bounding boxes of stove top, toy sink, ice cream, pepper, carrot.




- 제로샷과 퓨샷 기능으로 직접 로봇 제어 가능

구성요소

■ Gemini Robotics

- Gemini Robotics는 Gemini Robotics ER의 출력을 로봇 행동으로 변환하도록 SFT로 학습한 VLA
- ALOHA 2 로봇에서 12개월 동안 teleoperation으로 수집한 수천 시간 분량의 시연 데이터 ((영상, 텍스트, 센서) 데이터에 행동이 레이블링된 형태)
- VLA 백본 (클라우드에서 동작)과 로봇에서 동작하는 행동 디코더로 구성 (전체 처리 속도는 50Hz의 실시간)



성능 실험

■ Gemini Robotics의 out-of-box 성능 실험

- 솜씨 조작 dexterous manipulation

“open the eyeglasses case”



- 시각 효과에 대한 일반화 능력

In-distribution	Distractors	Different background	Different lighting conditions
Put the top left green grapes into the right compartment of the grey box.			

- 언어 일반화 능력

Initial scene	In-distribution	Typo	Multilingual	Rephrasing	Descriptive
	Put the top left green grapes into the right compartment of the grey box.	Put the top lft gren grapes into the rht comprtment of the grey bx.	Coloque las uvas verdes de la parte superior izquierda en el compartimento derecho de la caja gris.	Pick up the green grapes and place them in the largest container of the grey box.	Pick the green grapes (top left) and put them in the grey box (right compartment).

성능 실험


■ Gemini Robotics의 적응 능력 실험 (SFT로 특정 과업으로 전이)

- 긴 수평선의 솜씨 과업 (2천~5천 개의 에피소드로 SFT)

“make an origami fox”



- 리즈닝과 일반화 향상



- 빠른 적응 (대략 15분~1시간 분량의 시연 데이터)

LLM은 월드 모델인가?

■ 활발한 논쟁이 진행중임

입장	핵심 주장	대표 논문/자료	주요 키워드
찬성 입장 (LLM ≈ World Model 가능성)	LLM이 언어를 통해 간접적이지만 세계(state) 변화, 인과 관계, 계획 등을 어느 정도 모델링할 수 있으며, 따라서 월드 모델로서의 기능 일부를 갖출 수 있다는 주장	Reasoning with Language Model is Planning with World Model (Hao et al., 2023) arXiv +3	planning, latent state prediction, reasoning = planning
반대 입장 (LLM은 월드 모델이 아니다)	LLM은 주로 다음 토큰 예측(next-token prediction)에 기반하며, 진정한 월드 모델이 갖춰야 할 “물리적 세계 상태 전이”, “몸체(action)와 상호작용”, “장기 시뮬레이션(imagination)” 등이 부족하다는 주장	Critiques of World Models (Xing et al., 2025) arXiv +1 The debate over understanding in AI’s large language models (Mitchell & Krakauer, 2023) PNAS	embodiment, sensorimotor grounding, simulation horizon, actionable possibilities
중립/혼합 입장	LLM가 월드 모델의 일부 요소는 갖추지만 완전한 월드 모델이라 보기엔 부족하며, 향후 멀티모달 + 행동체(agentic) 통합이 필요하다는 복합 관점	Melanie Mitchell's blog “LLMs and World Models, Part 1” aiguide.substack...	multi-modal, agentic integration, hybrid architectures

[Wong2023] Lionel Wong et al., “From word models to world models: translating from natural language to the probabilistic language of thought,” arXiv:2306.12672v2.

[Xie2024] Kaige Xie et al., “Making large language models into world models with precondition and effect knowledge,” arXiv:2409.12278v2.

[Feng2025] Jie Feng et al., “A survey of large language model-powered spatial intelligence across scales: advances in embodied agents, smart cities, and earth science,” arXiv:2504.09848v1.



자율주행

자율주행

- 현재 Waymo의 로보택시는 상업 운행 중임
 - 피닉스, 샌프란시스코, 오스틴, 로스앤젤레스, 아틀랜타에서 영업
- 고수준 자동화인 수준 4 해당
 - 고해상도 지도에 의존
 - 날씨에 따라 운행 제한



그림 13-13 자율주행 실시간 장면[Waymo2025]

자율주행의 현재

■ 구현 방식

- 모듈을 따로 설계하고 구현하여 이어 붙이는 모듈 방식
 - 자동차 동작에 대한 해석 가능성이 장점이지만, 확장성 측면에서 불리
- 전체 모델을 한꺼번에 학습하는 통째 방식
 - 해석 가능성 측면에서 불리하지만 확장성 뛰어남
- 모듈 방식에서 통째 방식으로 전환하는 추세이며, 월드 모델에 더욱 의존



(a) 모듈 방식



(b) 순수 통째 방식



(c) 부분 통째 방식

그림 13-14 자율주행 구현 방식

자율주행의 현재

■ 자율주행 과업의 특성

- 시연 데이터 수집이 비교적 쉬움
 - 운행 기록장치를 부착한 차량을 전문 운전자가 운행하면서 수집
 - 공개된 시뮬레이터 다수
- 긴 꼬리^{long-tail} 현상
 - 정상 상황의 빈도는 매우 높고, 비정상 위급 상황은 빈도는 매우 낮거나 없음
 - 위급 상황이 매우 중요




그림 13-15 자율주행 운행 상황의 발생 빈도와 긴 꼬리

■ 이들 특성으로 인해 주로 흉내 학습과 강화 학습을 결합하여 구현

- 흉내 학습을 통해 사람의 운전 습관을 배우고, 강화 학습을 통해 위험 상황 대처를 배움

데이터셋과 시뮬레이터

■ 데이터셋

- 웨이모 (<https://waymo.com/open/>)




- nuScenes (<https://www.nuscenes.org/>)




- Argoverse 2 (<https://www.argoverse.org/av2.html>)

■



■ 시뮬레이터



- Carla (<https://carla.org/>)



■

월드 모델-기반 자율주행

■ 개념도와 발전 역사 [Guan2024]



서베이 논문

[Guan2024] Y. Guan et al., "World models for autonomous driving: an initial survey," IEEE Tr. On Intelligent Vehicles.

[Fu2024] A. Fu et al., "Exploring the interplay between video generation and world models in autonomous driving: a survey," arXiv:2411.02914.

[Feng2025] T. Feng et al., "A survey of world models for autonomous driving," arXiv:2501.11260v3.



GAIA

개요

■ Wayve의 GAIA-1


- 자율주행에서 가장 중요한 것은 행동을 취함에 따라 미래가 어떻게 펼쳐질지 예측하는 일
- GAIA-1은 월드 모델을 기반으로 멀티모달 프롬프트에 따라 미래 비디오를 예측

MODE	CONTEXT	CONDITIONING	GENERATED FRAMES
Video rollout			
Action-conditioned rollout		Action: Speed: -- Curvature: LEFT	
Text-conditioned rollout		Text: "The traffic light is green"	
Text and action conditioned generation		Text: "We are 15 meters behind a bus" Action: Speed: ACCELERATE Curvature: RIGHT	

구조와 학습

■ 모델

- 토크나이저, 월드 모델, 비디오 디코더로 구성




■ 토크나이저

- 비디오 ($x_1, x_2, \dots, x_T$)를 비디오 토큰 ($z_1, z_2, \dots, z_T$)로 변환, 텍스트를 텍스트 토큰 ($c_1, c_2, \dots, c_T$)로 변환, 행동을 행동 토큰 ($a_1, a_2, \dots, a_T$)로 변환
- 모든 토큰은 벡터양자화를 거쳐 이산 벡터이고, linear 층을 통해 d 차원으로 변환

GAIA-2

GAIA-1을 향상한 GAIA-2

- 다중 에이전트, 다중 카메라, fine-grained 제어 강화
- 토큰을 연속 공간에 표현하여 비디오 품질 개선
- 다양한 프롬프트: 지역, 도로 유형, 보행자, 신호등, 교차로 유형 등이 추가됨
- 다양한 조건 주기conditioning: 3D BB과 인페인팅



그리고 ...

- DriveDreamer [Wang2023]와 DriveDreamer-2 [Zhao2024]
- WorldDreamer [Wang2024]
- Copilot4d [Zhang2024]
- AD-L-JEPA [Zhue2025]
- ...

[Wang2023] X. Wang et al., "DriveDreamer: towards real-world-driven world models for autonomous driving," arXiv:2309.09777v2.

[Zhao2024] G. Zhao et al., "DriveDreamer-2: LLM-enhanced world models for diverse driving video generation," arXiv:2402.06845v2.

[Wang2024] X. Wang et al., "WorldDreamer: towards general world models for video generation via predicting masked tokens," arXiv:2401.09985.

[Zhang2024] L. Zhang et al., "Copilot4d: learning unsupervised world models for autonomous driving via discrete diffusion," ICLR.

[Zhu2025] H. Zhu et al., "Self-supervised representation learning with JEPA for automotive LiDAR object detection," arXiv:2501.04969v2.



AGI에 대한 논쟁과 도전

들뜬 AGI

■ 철학자 (미래학자에 가까운) 보스트롬 (『Superintelligence』 저자)

- “There’s a good likelihood that by 2050, all scientific research will be done by superintelligent AI rather than human researchers. Some humans might do science as a hobby, but they wouldn’t be making any useful contributions.” (David Adam, “Science in 2050: the future breakthroughs that will shape our world - and beyond” Nature, January 2026.

■ Jeff Hawkins 『천 개의 뇌』

- “... .. 더욱 놀라운 것은 기술 분야의 권위자들이 ‘AI는 결코 실현되지 못할 것이다’에서 ‘AI는 가까운 미래에 모든 인류를 파멸시킬 가능성이 있다’로 하루아침에 입장을 확 바꾸었다는 사실이다. AI의 실존적 위험을 연구하기 위해 비영리 연구소와 싱크탱크가 여러 곳 설립되었고, 이목을 끌기 좋아하는 다수의 기술자와 과학자, 철학자가 지능 기계의 탄생이 인류의 급속한 멸망이나 예측 상태를 초래할 수 있다고 공개적으로 경고하고 나섰다. 이제 많은 사람이 인공 지능이 인류에게 실존적 위험이라고 간주한다.”
- “... .. 이런 시나리오를 읽을 때, 나는 인런 염려들이 지능이 무엇인지에 대한 이해가 거의 없는 상태에서 나온 주장이라는 느낌을 받는다.”

AGI 겨울?

- AGI의 겨울이 올 듯... 하지만 따스한 겨울...



AGI에 대한 논쟁

■ AGI의 불꽃 [Bubeck2023]

- 현대 LLM (GPT-4와 GPT-5)에 대한 정성적이고 정량적인 평가
- 예) 운(rhyme)을 맞추어 수학 정리를 증명 & 영상 이해

Prompt: Can you write a proof that there are infinitely many primes, with every line that rhymes?

GPT-4:

```
Yes, I think I can,  
Though it might take a clever plan.  
I'll start by noting Euclid's proof,  
Which shows that primes aren't just aloof.  
Assume we have a finite list,  
Of primes, and that none have been missed.  
Multiply them all together,  
And add one, just to be clever.  
The result will be a number,  
That has no prime factors, oh wonder!  
But every number has a prime,  
That divides it, it's just a matter of time.  
So we've found a contradiction,  
And our finite list needs eviction.  
There must be infinitely many primes,  
And that's the end of my rhyming lines.s
```

User prompt: What is unusual about this image?




GPT-4: The unusual thing about this image is that a man is ironing clothes on an ironing board attached to the roof of a moving taxi.


AGI에 대한 논쟁

■ AGI의 점수화 [Hendrycks2025]

- AGI를 10개 범주로 나누고, 각 범주를 세부 기능으로 나누고 점수화
- 현대 LLM (GPT-4와 GPT-5)의 성능을 점수화
- 한계: AGI를 개별 지능의 합으로 바라봄



Model	K	RW	M	R	WM	MS	MR	V	A	S	Total
GPT-4	8%	6%	4%	0%	2%	0%	4%	0%	0%	3%	27%
GPT-5	9%	10%	10%	7%	4%	0%	4%	4%	6%	3%	57%




AGI에 대한 논쟁

■ AGI를 여섯 단계로 구분 (자율주행에서 빌어옴) [Morris2023]

Performance (rows) x Generality (columns)	Narrow <i>clearly scoped task or set of tasks</i>	General <i>wide range of non-physical tasks, including metacognitive tasks like learning new skills</i>
Level 0: No AI	Narrow Non-AI calculator software; compiler	General Non-AI human-in-the-loop computing, e.g., Amazon Mechanical Turk
Level 1: Emerging <i>equal to or somewhat better than an unskilled human</i>	Emerging Narrow AI GOFAI (Boden, 2014); simple rule-based systems, e.g., SHRDLU (Winograd, 1971)	Emerging AGI ChatGPT (OpenAI, 2023), Bard (Anil et al., 2023), Llama 2 (Touvron et al., 2023), Gemini (Pichai & Hassabis, 2023)
Level 2: Competent <i>at least 50th percentile of skilled adults</i>	Competent Narrow AI toxicity detectors such as Jigsaw (Das et al., 2022); Smart Speakers such as Siri (Apple), Alexa (Amazon), or Google Assistant (Google); VQA systems such as PaLI (Chen et al., 2023); Watson (IBM); SOTA LLMs for a subset of tasks (e.g., short essay writing, simple coding)	Competent AGI not yet achieved
Level 3: Expert <i>at least 90th percentile of skilled adults</i>	Expert Narrow AI spelling & grammar checkers such as Grammarly (Grammarly, 2023); generative image models such as Imagen (Saharia et al., 2022) or Dall-E 2 (Ramesh et al., 2022)	Expert AGI not yet achieved
Level 4: Exceptional <i>at least 99th percentile of skilled adults</i>	Exceptional Narrow AI Deep Blue (Campbell et al., 2002), AlphaGo (Silver et al., 2016; 2017)	Exceptional AGI not yet achieved
Level 5: Superhuman <i>outperforms 100% of humans</i>	Superhuman Narrow AI AlphaFold (Jumper et al., 2021; Varadi et al., 2021), AlphaZero (Silver et al., 2018), StockFish (Stockfish, 2023)	Artificial Superintelligence (ASI) not yet achieved

사람 지능과 인공지능

- 무봉^{seamless}으로 과업 전환^{task transfer}이 가능한 사람의 일상생활 vs. 인공지능의 분절된 과업



- 계층 과업과 무봉 과업 전환에 능숙한 사람의 일상 생활 사례

사람은 달리기를 하다가 주머니에서 휴대폰이 울리면, 잠시 멈춰 통화를 하고, 가까운 의자를 찾아 앉은 후 인터넷 검색을 하며, 상대가 요청한 문서를 찾아 전송한 뒤, 다시 달리기를 이어 나간다. 이런 과업 전환은 봉합 자국 없이 자연스럽게 일어난다. 이처럼 달리기라는 하나의 과업은 서로 다른 성격의 소규모 과업의 연쇄로 이루어진다. 달리기 과업을 마치면 집에 가기 위해 운전 과업을 수행하고, 집에 도착하면 샤워 과업, 저녁 식사 과업, TV 시청 과업, 취침 과업이 연쇄적으로 일어난다. 이들 과업 각각은 고유한 소규모 과업의 연쇄로 이루어지기 때문에 과업은 계층화되어 있다고 말할 수 있다. 사람은 어떤 과업을 수행할 때 의도^{intention}가 분명하다. 의도는 과업을 촉발시키며 과업을 수행하는 과정을 제어한다. 중간에 돌발 상황이 발생하면 유연하게 대처하는 능력과 원래 과업으로 회복하는 능력이 뛰어나다.

AGI에 대한 도전

■ 월드 모델과 피지컬 AI



■ 분절된 과업을 이어보려는 다양한 노력

- VLA 로봇, 토대 모델과 월드 모델 등
- 다능 에이전트 *generalist agent*라고 불리는 Gato
- 메타 강화 학습
- Xland
- ...

AGI에 대한 도전

■ 르쿤의 구상 [LeCun2023]






Figure 2: A system architecture for autonomous intelligence. All modules in this model are assumed to be “differentiable” in that a module feeding into another one (through an arrow connecting them) can get gradient estimates of the cost’s scalar output with respect to its own output.

자율 과업 전환



과업의 계층적 처리



AGI에 대한 도전

■ 사람의 일상 생활을 시뮬레이션 [Yiding2025]

- Autonomy를 가진 AI
- 욕망 기반 플래닝




Figure 2: The Desire-Driven Autonomy framework. The red blocks represent procedures from the Value System, the blue blocks indicate procedures from the Desire-Driven Planner, the green blocks highlight the characteristics profile, and the yellow blocks correspond to elements related to the environment controller.

AGI에 대한 도전


■ 사람의 뇌 이론을 AGI에 접목해야한다는 주장 [Hawkins2021]

- Jeff Hawkins의 Thousand brains를 월드 모델과 연관지어 200여 단어로 요약(ChatGPT)

Jeff Hawkins의 **Thousand Brains Theory**는 최근의 월드 모델 연구와 공통적으로 지능의 핵심을 세계에 대한 내부 표현의 형성에서 찾는다. Dreamer나 MuZero와 같은 명시적 월드 모델은 잠재 공간에서 미래를 시뮬레이션하며, JEPA와 V-JEPA와 같은 암묵적 월드 모델은 세계의 구조적 규칙성을 표현 공간에 내재화한다. Hawkins 역시 지능이 세계의 구조를 학습하는 과정에서 발생한다고 본다는 점에서 이러한 연구들과 철학적 기반을 공유한다.

그러나 Hawkins의 이론은 현재 대부분의 월드 모델과 중요한 차이를 가진다. 현대 월드 모델이 하나의 거대한 신경망 안에 단일한 세계 모델을 학습하는 반면, Thousand Brains Theory는 수천 개의 피질 컬럼이 각각 독립적인 세계 모델을 형성한다고 주장한다. 각 컬럼은 부분적인 관찰만으로 객체와 환경을 이해하며, 최종적인 인식은 이들 모델의 합의(consensus)를 통해 형성된다.

또한 Hawkins는 객체 중심(object-centric) 및 위치 기반(location-based) 표현을 지능의 핵심 요소로 강조한다. 이는 최근 로봇과 Physical AI 연구에서 관심이 증가하고 있는 object-centric world model과도 밀접하게 연결된다. 따라서 Thousand Brains Theory는 현재의 월드 모델을 대체하는 이론이라기보다, 단일 거대 모델을 넘어 다수의 세계 모델이 협력하는 미래 AGI의 가능성을 제시하는 관점으로 해석할 수 있다.



신피질(neo-cortex)은 15만개의
피질 기둥(cortical column)으로 구성됨

경청해 주셔서 고맙습니다.